TRƯỜNG ĐẠI HỌC THỦY LỢI
KHOA CÔNG NGHỆ THÔNG TIN
TS. Tạ Quang Chiểu
TS. Nguyễn Thị Kim Ngân

BÀI TẬP
HỌC MÁY

Hà Nội, 06-2026

MỤC LỤC

Chương 1 GIỚI THIỆU VỀ HỌC MÁY 2
Chương 2 HỒI QUY TUYẾN TÍNH VÀ QUÁ KHỚP 5
Chương 3 GRADIENT DESCENT VÀ THUẬT TOÁN PERCEPTRON 9
Chương 4 MẠNG NƠ RON NHÂN TẠO 14
Chương 5 PHƯƠNG PHÁP HỌC THEO MÔ HÌNH CÂY 19
Chương 6 HỒI QUY LOGISTIC, MÁY VECTOR HỖ TRỢ 24
Chương 7 HỌC KHÔNG GIÁM SÁT 28
Chương 8 HỌC KẾT HỢP - ENSEMBLE LEARNING 33
ĐÁP ÁN BÀI TẬP TRẮC NGHIỆM 38

Chương 1 GIỚI THIỆU VỀ HỌC MÁY

A. Câu hỏi trắc nghiệm lý thuyết

Chọn phương án đúng nhất cho mỗi câu hỏi.

1.1 Theo Tom Mitchell, một chương trình được xem là "học" nếu nó cải thiện hiệu năng nhờ vào:
A. Tăng số lượng lõi CPU.
B. Tăng dung lượng RAM.
C. Kinh nghiệm E thu thập từ dữ liệu.
D. Được lập trình thêm các câu lệnh if-else.

1.2 Bài toán dự đoán giá cổ phiếu (một con số cụ thể) thuộc loại nào trong học có giám sát?
A. Phân loại nhị phân.
B. Phân loại đa lớp.
C. Hồi quy.
D. Phân cụm.

1.3 Trong học có giám sát, tập dữ liệu huấn luyện luôn bao gồm:
A. Chỉ các vector đặc trưng.
B. Các cặp (đặc trưng, nhãn).
C. Các nhãn được sinh ngẫu nhiên.
D. Không cần dữ liệu.

1.4 Phát biểu nào sau đây là đúng về học không giám sát?
A. Yêu cầu toàn bộ dữ liệu phải có nhãn.
B. Mục tiêu là dự đoán nhãn cho dữ liệu mới.
C. Máy tự tìm cấu trúc ẩn bên trong dữ liệu không có nhãn.
D. Luôn cho kết quả kém hơn học có giám sát.

1.5 Thuật toán K-means thuộc nhóm:
A. Học có giám sát - hồi quy.
B. Học có giám sát - phân loại.
C. Học không giám sát - phân cụm.
D. Học tăng cường.

1.6 Định lý Bayes được dùng để:
A. Tính khoảng cách Euclid giữa hai điểm.
B. Ước lượng xác suất hậu nghiệm dựa trên bằng chứng mới.
C. Tối thiểu hóa hàm mất mát MSE.
D. Nhân hai ma trận lớn.

1.7 Trong công thức cập nhật của gradient descent: $\mathrm{w} := \mathrm{w} - \eta L(\mathrm{w})$, η là:
A. Gradient của hàm mất mát.
B. Số vòng lặp hiện tại.
C. Tốc độ học (learning rate).
D. Giá trị hàm mất mát hiện tại.

1.8 Hàm mất mát nào thường được dùng cho bài toán hồi quy?
A. Cross-entropy.
B. Hinge loss.
C. Mean Squared Error (MSE).
D. Accuracy.

1.9 Làm mượt Laplace (Laplace smoothing) trong Naive Bayes nhằm mục đích:
A. Tăng tốc độ huấn luyện.
B. Tránh xác suất bằng 0 cho các từ chưa từng xuất hiện trong một lớp.
C. Giảm số chiều của vector đặc trưng.
D. Chuẩn hóa dữ liệu về dạng phân phối chuẩn.

1.10 Ma trận $\mathbf{X} \in \mathbb{R}^{m \times n}$ có nghĩa là:
A. m mẫu, mỗi mẫu có n đặc trưng.
B. n mẫu, mỗi mẫu có m đặc trưng.
C. m đặc trưng và n nhãn.
D. m lớp và n mẫu.

1.11 Overfitting xảy ra khi:
A. Mô hình quá đơn giản, không nắm được quy luật dữ liệu.
B. Mô hình học cả nhiễu trong tập huấn luyện, dự đoán kém trên dữ liệu mới.
C. Tập huấn luyện quá nhỏ nên không thể học.
D. Tốc độ học quá cao khiến mô hình phân kỳ.

1.12 Thuật toán nào dưới đây là **học có giám sát**?
A. K-means.
B. PCA.
C. Cây quyết định (Decision Tree).
D. DBSCAN.

1.13 Học bán giám sát phù hợp nhất khi:
A. Tất cả dữ liệu đã có nhãn đầy đủ.
B. Chỉ một phần nhỏ dữ liệu có nhãn, phần lớn không nhãn.
C. Hoàn toàn không có dữ liệu có nhãn.
D. Máy học bằng cách thử và sai với môi trường.

1.14 Tích vô hướng của hai vector càng lớn khi chúng:
A. Càng khác hướng.
B. Vuông góc.
C. Càng cùng hướng và có độ lớn lớn.
D. Một trong hai là vector không.

1.15 Chuẩn L_2 của một vector dùng để đo:
A. Tổng các phần tử của vector.
B. Độ dài Euclid của vector.
C. Phần tử lớn nhất.
D. Số phần tử khác 0.

1.16 Trong bài toán lọc spam, ký hiệu $P(\text{“mua”} \mid \text{Spam})$ biểu thị:
A. Xác suất một email là spam.
B. Xác suất từ “mua” xuất hiện trong bất kỳ email nào.
C. Xác suất từ “mua” xuất hiện với điều kiện email đó là spam.
D. Xác suất email là spam khi thấy từ “mua”.

1.17 Ứng dụng nào sau đây không điển hình cho học máy?
A. Nhận dạng khuôn mặt trong ảnh.
B. Dịch tự động văn bản.
C. Biên dịch tài liệu bằng cách tra từ điển thủ công.
D. Phát hiện giao dịch gian lận.

1.18 Nếu tốc độ học η quá lớn, điều gì thường xảy ra với hạ gradient?
A. Hàm mất mát giảm đều và ổn định.
B. Hàm mất mát dao động mạnh hoặc phân kỳ.
C. Mô hình tự điều chỉnh η.
D. Mô hình chuyển sang trạng thái underfitting.

1.19 Mục tiêu chính của giảm chiều dữ liệu là:
A. Tăng số lượng đặc trưng.
B. Giảm số chiều nhưng vẫn giữ được thông tin quan trọng, giảm nhiễu.
C. Gom dữ liệu thành các cụm.
D. Chuyển bài toán hồi quy thành phân loại.

1.20 Phát biểu nào đúng về Naive Bayes?
A. Nó giả định các đặc trưng phụ thuộc lẫn nhau.
B. Nó không thể dùng cho dữ liệu văn bản.
C. Nó dựa trên Định lý Bayes và giả định các đặc trưng độc lập có điều kiện với lớp.
D. Nó là thuật toán học không giám sát.

Chương 2 HỒI QUY TUYẾN TÍNH VÀ QUÁ KHỚP

A. Câu hỏi trắc nghiệm lý thuyết

Chọn một phương án đúng nhất cho các câu từ 1 đến 20.

2.1 Mục tiêu của Linear Regression là:

A. Phân loại dữ liệu

B. Dự báo giá trị liên tục

C. Giảm số lượng dữ liệu

D. Tăng số chiều dữ liệu

2.2 Phương trình của mô hình hồi quy tuyến tính đơn có dạng:

A. $y=wx^2+b$

B. $y=wx+b$

C. $y=ln(x+b)$

D. $y=e^{wx+b}$

2.3 Trong Linear Regression, w thường biểu diễn:

A. Sai số mô hình

B. Trọng số của các features (weight)

C. Số lượng dữ liệu

D. Giá trị đầu ra

2.4 Trong Linear Regression, b thường được gọi là:

A. Weight

B. Learning rate

C. Bias (intercept)

D. Loss function

2.5 Hàm mất mát phổ biến nhất trong Linear Regression là:

A. Cross-Entropy

B. Mean Squared Error (MSE)

C. Accuracy

D. Hinge Loss

2.6 Mục tiêu của quá trình huấn luyện Linear Regression là:

A. Tối thiểu hóa MSE

B. Tối đa hóa MSE

C. Tăng số lượng feature

D. Giảm kích thước dữ liệu

2.7 Training error là gì?

A. Sai số trên tập huấn luyện

B. Sai số trên tập kiểm tra

C. Sai số trên validation set

D. Sai số trung bình của toàn bộ dữ liệu

2.8 Test error được tính trên tập dữ liệu nào?

A. Training set

B. Validation set

C. Test set

D. Toàn bộ dữ liệu

2.9 Một mô hình được xem là overfitting khi:

A. Training error cao, test error thấp

B. Training error thấp, test error cao

C. Training error cao, test error cao

D. Training error thấp, test error thấp

2.10 Một mô hình được xem là underfitting khi:

A. Training error thấp, test error cao

B. Training error cao, test error cao

C. Training error thấp, test error thấp

D. Training error cao, test error thấp

2.11 Khi độ phức tạp của mô hình tăng lên, training error thường:

A. Không đổi

B. Dao động ngẫu nhiên

C. Tăng

D. Giảm

2.12 Validation được sử dụng để:

A. Giảm số lượng feature

B. Chuẩn hóa dữ liệu

C. Tăng kích thước dữ liệu

D. Đánh giá khả năng tổng quát hóa của mô hình

2.13 Validation set được lấy từ đâu?

A. Test set

B. Toàn bộ dữ liệu

C. Training set

D. Dữ liệu mới

2.14 Mô hình tốt thường là mô hình có:

A. Validation error lớn nhất

B. Training error lớn nhất

C. Validation error nhỏ nhất

D. Test error lớn nhất

2.15 Trong K-Fold Cross Validation, dữ liệu được chia thành:

A. 2 phần

B. 3 phần

C. K phần bằng nhau

D. N phần ngẫu nhiên

2.16 Trong K-Fold Cross Validation, ở mỗi lần lặp:

A. Tất cả dữ liệu đều dùng để train

B. Một fold dùng để validation

C. Một fold dùng để test

D. Không cần validation

2.17 Cross-validation đặc biệt hữu ích khi:

A. Có rất nhiều dữ liệu

B. Dữ liệu ít

C. Không có nhiễu

D. Chỉ có một feature

2.18 Regularization nhằm mục đích chính là:
A. Tăng số lượng dữ liệu
B. Giảm độ phức tạp mô hình
C. Tăng số lượng tham số
D. Loại bỏ training set

2.19 Trong Early Stopping, khi nào quá trình huấn luyện nên dừng?
A. Khi test error giảm
B. Khi số epoch bằng 0
C. Khi training error tăng
D. Khi validation error có xu hướng tăng

2.20 Mục tiêu của regularized loss function là:
A. Chỉ tối thiểu hóa training error
B. Chỉ tối thiểu hóa regularization term
C. Đồng thời tối thiểu hóa loss và regularization term
D. Tăng số lượng feature

B. Câu hỏi tự luận và bài tập

2.21 Trình bày khái niệm overfitting và underfitting. Nêu cách nhận biết hai hiện tượng này thông qua training error và test error.

2.22 Trình bày nguyên lý hoạt động của K-Fold Cross Validation.

2.23 Giải thích kỹ thuật Early Stopping. Vì sao Early Stopping được xem là một phương pháp regularization?

2.24 So sánh LASSO Regularization và RIDGE Regularization về:

- công thức,
- cơ chế hoạt động,
- khả năng lựa chọn đặc trưng,
- trường hợp sử dụng phù hợp.

2.25 Chọn một tập dữ liệu để thực hiện bài toán hồi quy (ví dụ, tập dữ liệu về giá nhà, tập dữ liệu về điểm thi, …). Sử dụng các phương pháp đã được học để xây dựng mô hình dự báo đạt kết quả tốt nhất theo các độ đo R2, NSE, MAE, RMSE.

Chương 3 GRADIENT DESCENT VÀ THUẬT TOÁN PERCEPTRON

A. Câu hỏi trắc nghiệm lý thuyết

3.1 Gradient Descent là thuật toán được sử dụng chủ yếu để:
A. Giảm số chiều dữ liệu
B. Tối ưu hàm mục tiêu bằng cách tìm cực trị
C. Phân cụm dữ liệu
D. Trực quan hóa dữ liệu

3.2 Trong Gradient Descent, tham số η (learning rate) có ý nghĩa là:
A. Số lượng dữ liệu huấn luyện
B. Số vòng lặp
C. Kích thước bước cập nhật tham số
D. Độ chính xác của mô hình

3.3 Công thức cập nhật tham số trong Gradient Descent là:
A. $w \leftarrow w+\eta \nabla L(w)$
B. $w \leftarrow \eta \nabla L(w)$
C. $w \leftarrow w-\eta \nabla L(w)$
D. $w \leftarrow \nabla L(w)$

3.4 Điều kiện dừng thường dùng của Gradient Descent là:
A. Gradient xấp xỉ bằng 0
B. Dữ liệu huấn luyện hết
C. Sai số bằng 1
D. Learning rate bằng 0

3.5 Nếu learning rate quá nhỏ thì:
A. Thuật toán phân kỳ
B. Hội tụ chậm
C. Không cập nhật trọng số
D. Luôn tìm được nghiệm tối ưu toàn cục

3.6 Nếu learning rate quá lớn thì:
A. Hội tụ chậm
B. Không ảnh hưởng kết quả
C. Có thể dao động lớn và bỏ qua điểm tối ưu
D. Gradient luôn bằng 0

3.7 Batch Gradient Descent sử dụng:
A. Một mẫu dữ liệu mỗi lần cập nhật
B. Một mini-batch dữ liệu
C. Toàn bộ tập huấn luyện
D. Chỉ dữ liệu kiểm tra

3.8 Độ phức tạp tính toán cho mỗi lần cập nhật của Batch Gradient Descent là:
A. O(1)
B. O(logN)
C. O(N)
D. $O(N^2)$

3.9 Stochastic Gradient Descent cập nhật trọng số dựa trên:
A. Toàn bộ dữ liệu
B. Một mẫu dữ liệu ngẫu nhiên
C. Một mini-batch
D. Tập kiểm tra

3.10 Ưu điểm lớn nhất của SGD là:
A. Luôn hội tụ tối ưu toàn cục
B. Chi phí cập nhật thấp
C. Không cần learning rate
D. Không phụ thuộc dữ liệu

3.11 Mini-batch Gradient Descent kết hợp ưu điểm của:
A. KNN và SVM
B. SGD và Decision Tree
C. Batch GD và SGD
D. PCA và K-Means

3.12 Thuật toán Perceptron được đề xuất bởi:
A. Geoffrey Hinton
B. Yann LeCun
C. Frank Rosenblatt
D. Andrew Ng

3.13 Perceptron được thiết kế cho bài toán:
A. Hồi quy tuyến tính
B. Phân lớp nhị phân
C. Phân cụm
D. Giảm chiều dữ liệu

3.14 Trong Perceptron, nhãn của một mẫu x được xác định dựa trên:
A. Khoảng cách Euclid
B. Dấu của $w^T x$
C. Giá trị trung bình
D. Hàm sigmoid

3.15 Quy tắc cập nhật trọng số của Perceptron là:
A. w←w−yx
B. w←yxw
C. w←w+yw
D. w←w+yx

3.16 Điều kiện để Perceptron đảm bảo hội tụ là:
A. Dữ liệu phân tách tuyến tính được
B. Dữ liệu cân bằng lớp
C. Dữ liệu chuẩn hóa
D. Learning rate nhỏ

3.17 Precision được tính bằng:
A. TP/(TP+FN)
B. TP/(TP+FP)
C. (TP+TN)/N
D. TN/(TN+FP)

3.18 F1-score là:
A. Trung bình điều hòa của Precision và Recall
B. Trung bình hình học của Precision và Recall
C. Trung bình cộng của Precision và Recall
D. Sai số trung bình

3.19 Một tập dữ liệu có 50.000 mẫu. Để huấn luyện mô hình theo thời gian thực (online learning), phương pháp nào phù hợp nhất?
A. Batch Gradient Descent
B. Perceptron với learning rate bằng 0
C. Phương pháp giải đạo hàm bằng 0
D. Stochastic Gradient Descent

3.20 Giả sử một mini-batch có kích thước k=50 và tập dữ liệu có N=1000 mẫu. Một epoch của Mini-batch Gradient Descent thực hiện xấp xỉ bao nhiêu lần cập nhật trọng số?
A. 50
B. 1000
C. 500
D. 20

B. Câu hỏi tự luận và bài tập

3.21 Trình bày ý tưởng cơ bản của thuật toán Gradient Descent.

- Giải thích tại sao Gradient Descent di chuyển theo hướng ngược với gradient.
- Vai trò của tham số learning rate.
- Điều kiện dừng của thuật toán.

3.22 So sánh ba phương pháp:

- Batch Gradient Descent (BGD)
- Stochastic Gradient Descent (SGD)
- Mini-batch Gradient Descent (MBGD)

Theo các tiêu chí:

- Dữ liệu sử dụng cho mỗi lần cập nhật.
- Chi phí tính toán.
- Tốc độ hội tụ.
- Ưu điểm và nhược điểm.
- Trường hợp áp dụng phù hợp.

3.23 Learning rate ảnh hưởng như thế nào đến quá trình tối ưu của Gradient Descent? Phân tích các trường hợp:

- Learning rate quá nhỏ.
- Learning rate quá lớn.
- Learning rate hợp lý.

Cho ví dụ minh họa.

3.24 Trình bày nguyên lý hoạt động của thuật toán Perceptron.

- Bài toán mà Perceptron giải quyết.
- Khái niệm siêu phẳng phân tách.
- Cách dự đoán nhãn của một mẫu mới.
- Quy tắc cập nhật trọng số.

3.25 Giải thích các độ đo đánh giá mô hình phân lớp:

- Accuracy
- Precision
- Recall
- F1-score

Trong trường hợp phát hiện bệnh hoặc phát hiện gian lận giao dịch, độ đo nào quan trọng hơn Accuracy? Giải thích.

3.26 Cho hàm số: $f(x)=x^2-4x+5$

Thực hiện Gradient Descent với:

- Điểm khởi tạo $x^{(0)}=5$
- Learning rate $\eta=0.2$

Yêu cầu:

1. Tính đạo hàm $f'(x)$.
2. Thực hiện 4 bước cập nhật.
3. Tính giá trị hàm số tại mỗi bước.
4. Nhận xét sự hội tụ của thuật toán.

3.27 Cho: $w=[1, 2, -10]^T$, $x=[3, 4, 1]^T$ và điểm dữ liệu đã thêm bias.

Sử dụng phương pháp Perceptron:

1. Tính w^Tx.
2. Xác định nhãn dự đoán của điểm dữ liệu.
3. Nếu nhãn thực tế là $y=-1$, điểm dữ liệu có bị phân lớp sai không?

3.28 Cho: $w=[-2, 1, 0]^T$, $x=[2, 3, 1]^T$, $y=1$, trong đó, x đã thêm bias.

Sử dụng phương pháp Perceptron:

1. Kiểm tra mẫu có bị phân lớp sai hay không.
2. Nếu sai, thực hiện một bước cập nhật Perceptron.
3. Tính lại giá trị w^Tx sau cập nhật.

3.29 Viết code để xây dựng lớp Perceptron có hàm fit để huấn luyện mô hình và hàm predict để dự báo nhãn của dữ liệu mới.

3.30 Chọn một tập dữ liệu để thực hiện bài toán phân lớp nhị phân (ví dụ, tập dữ liệu về giao dịch có là gian lận hay không, …). Sử dụng phương pháp Perceptron để xây dựng mô hình dự báo đạt kết quả tốt nhất theo các độ đo Accuracy, Precision, Recall, F1-score.

Chương 4 MẠNG NƠ RON NHÂN TẠO

A. Câu hỏi trắc nghiệm lý thuyết

4.1 Trong nơ-ron nhân tạo, các giá trị x1, x2, …, xm được gọi là:
A. Trọng số
B. Đầu vào
C. Bias
D. Đầu ra

4.2 Trong nơ-ron nhân tạo, wi biểu diễn:
A. Đầu vào
B. Sai số
C. Trọng số kết nối
D. Đầu ra

4.3 Bias trong mạng nơ-ron thường được sử dụng để:
A. Tăng số lượng dữ liệu
B. Dịch chuyển hàm kích hoạt
C. Giảm số nơ-ron
D. Chuẩn hóa dữ liệu

4.4 Tầng nào của mạng nơ-ron nhận dữ liệu trực tiếp từ bên ngoài?
A. Hidden Layer
B. Output Layer
C. Input Layer
D. Activation Layer

4.5 Tầng nào của mạng nơ-ron tạo ra kết quả dự đoán cuối cùng?
A. Input Layer
B. Hidden Layer
C. Output Layer
D. Bias Layer

4.6 Trong mạng nơ-ron nhân tạo, tầng ẩn (Hidden Layer) là tầng:
A. Nằm giữa tầng đầu vào và tầng đầu ra
B. Tạo ra kết quả dự đoán cuối cùng
C. Nhận dữ liệu trực tiếp từ tập dữ liệu
D. Chỉ chứa các bias

4.7 Tại sao gọi là "tầng ẩn" (Hidden Layer)?
A. Vì không có nơ-ron nào trong tầng
B. Vì người dùng không quan sát trực tiếp các giá trị của tầng này từ dữ liệu đầu vào hoặc đầu ra
C. Vì tầng này luôn có giá trị bằng 0
D. Vì tầng này không tham gia tính toán

4.8 Vai trò chính của tầng ẩn là:
A. Lưu trữ dữ liệu huấn luyện
B. Trích xuất và học các đặc trưng từ dữ liệu
C. Chuẩn hóa dữ liệu
D. Chia dữ liệu thành các nhóm

4.9 Trong thư viện sklearn, khai báo hidden_layer_sizes=(3,2), nghĩa là:
A. Một tầng ẩn gồm 5 nơ-ron
B. Hai tầng đầu ra
C. Ba tầng ẩn
D. Hai tầng ẩn, lần lượt có 3 và 2 nơ-ron

4.10 Mục đích của việc sử dụng nhiều tầng ẩn là:
A. Học được các mối quan hệ phi tuyến phức tạp hơn
B. Giảm số lượng trọng số
C. Loại bỏ dữ liệu nhiễu
D. Giảm kích thước dữ liệu

4.11 Nếu tất cả các nơ-ron trong tầng ẩn sử dụng hàm tuyến tính f(x)=x, thì việc thêm nhiều tầng ẩn sẽ:
A. Luôn làm tăng độ chính xác
B. Giảm số trọng số
C. Loại bỏ overfitting
D. Không làm tăng khả năng biểu diễn phi tuyến của mạng

4.12 Một tầng ẩn có 5 nơ-ron nhận tín hiệu từ 3 đầu vào. Không tính bias, số trọng số cần học là:
A. 8
B. 10
C. 15
D. 20

4.13 Lan truyền xuôi (Forward Propagation) là quá trình:
A. Tính gradient
B. Tính đầu ra của mạng từ dữ liệu đầu vào
C. Cập nhật trọng số
D. Chuẩn hóa dữ liệu

4.14 Hàm mất mát (Loss Function) được sử dụng để:
A. Đo mức độ sai khác giữa giá trị dự đoán và giá trị thực
B. Tăng số lượng nơ-ron
C. Giảm kích thước dữ liệu
D. Tạo dữ liệu mới
4.15 Backpropagation được sử dụng để:
A. Tính đầu ra của mạng
B. Tính gradient của hàm mất mát
C. Chuẩn hóa dữ liệu
D. Tăng số tầng ẩn

4.16 Trong quá trình lan truyền ngược, sai số được truyền theo hướng:
A. Input → Output
B. Input → Hidden
C. Output → Input
D. Ngẫu nhiên

4.17 Gradient Descent được sử dụng để:
A. Cập nhật trọng số nhằm giảm hàm mất mát
B. Tăng số lượng dữ liệu
C. Chia dữ liệu thành các cụm
D. Chuẩn hóa dữ liệu

4.18 Mục tiêu cuối cùng của quá trình huấn luyện mạng nơ-ron là:
A. Tăng số lượng tầng
B. Tăng số lượng trọng số
C. Giảm giá trị của hàm mất mát
D. Tăng số lượng mẫu dữ liệu

4.19 Cho mạng nơ-ron có cấu tạo gồm:
tầng đầu vào có 2 nơ-ron,
1 tầng ẩn có 2 nơ-ron,
tầng đầu ra có 1 nơ-ron,
hàm kích hoạt là ReLU,

Cho $x = \begin{bmatrix}1\\2\end{bmatrix}$; $W^{(1)} = \begin{bmatrix}1 & 0\\0 & 1\end{bmatrix}$; $W^{(2)} = [1 \quad 1]$

Mạng nơ-ron này không có bias. Giá trị đầu ra ở tầng đầu ra (ouput layer) là:
A. 1
B. 2
C. 3
D. 4

4.20 Cho mạng nơ-ron có cấu tạo gồm:
tầng đầu vào có 2 nơ-ron,
1 tầng ẩn có 2 nơ-ron,
tầng đầu ra có 1 nơ-ron,
hàm kích hoạt là ReLU,

Cho vector đặc trưng $x = \begin{bmatrix}1\\2\end{bmatrix}$; nhãn của x là y=5; $W^{(1)} = \begin{bmatrix}1 & 0\\0 & 1\end{bmatrix}$; $W^{(2)} = [1 \quad 1]$;

hàm mất mát $J = \frac{1}{2}(y - \hat{y})^2$.

Hãy tính $\frac{\partial J}{\partial W^{(2)}}$.

A. [2, 4]
B. [1, 2]]
C. [-1, -2]
D. [-2, -4]

B. Câu hỏi tự luận và bài tập

4.21 Trình bày cấu trúc của một mạng nơ-ron nhiều lớp (Multilayer Neural Network).
Giải thích vai trò của:
Input Layer
Hidden Layer
Output Layer
Tại sao mạng nhiều tầng có khả năng học các mối quan hệ phi tuyến phức tạp?

4.22 Trình bày quá trình lan truyền xuôi (Forward Propagation) trong mạng nơ-ron.

4.23 Trình bày nguyên lý hoạt động của thuật toán lan truyền ngược (Backpropagation).
Giải thích:
Gradient
Gradient Descent
Learning Rate
và vai trò của chúng trong quá trình huấn luyện mạng nơ-ron.

4.24 Cho mạng nơ-ron có cấu tạo gồm:
tầng đầu vào có 2 nơ-ron,
1 tầng ẩn có 2 nơ-ron,
tầng đầu ra có 1 nơ-ron,
hàm kích hoạt là ReLU,

Cho $x = \begin{bmatrix}1\\2\end{bmatrix}$; $W^{(1)} = \begin{bmatrix}1 & 0\\0 & 1\end{bmatrix}$; $W^{(2)} = [1 \quad 1]$

Không có bias.

Tính $z^{(1)}$, $a^{(1)}$, $z^{(2)}$, $z^{(1)}$ và đầu ra cuối cùng của mạng.

4.25 Cho mạng nơ-ron có cấu tạo gồm:
tầng đầu vào có 2 nơ-ron,
1 tầng ẩn có 2 nơ-ron,
tầng đầu ra có 1 nơ-ron,
hàm kích hoạt là ReLU,

Cho $x = \begin{bmatrix}1\\2\end{bmatrix}$; $W^{(1)} = \begin{bmatrix}1 & 0\\0 & 1\end{bmatrix}$; $W^{(2)} = [1 \quad 1]$;

không có bias; giả sử y=5 và hàm mất mát $J = \frac{1}{2}(y - \hat{y})^2$.

Tính gradient $\frac{\partial J}{\partial W^{(1)}}$.

4.26 Viết code để xây dựng quá trình huấn luyện từ đầu một mạng nơ-ron với đầu vào (X,y), số các tầng ẩn và số nơ ron ở mỗi tầng ẩn là tùy ý, số nơ-ron ở tầng đầu ra là tùy ý (tùy thuộc bài toán tối ưu là bài toán hồi quy hay phân lớp).

4.27 Chọn một tập dữ liệu để thực hiện bài toán hồi quy (ví dụ, tập dữ liệu về giá nhà, tập dữ liệu về điểm thi, …). Sử dụng mạng nơ-ron để xây dựng mô hình dự báo đạt kết quả tốt nhất theo các độ đo R2, NSE, MAE, RMSE.

4.28 Chọn một tập dữ liệu để thực hiện bài toán phân lớp. Sử dụng mạng nơ-ron để xây dựng mô hình dự báo đạt kết quả tốt nhất theo các độ đo Accuracy, Precision, Recall, F1-score.

Chương 5 PHƯƠNG PHÁP HỌC THEO MÔ HÌNH CÂY

A. Câu hỏi trắc nghiệm lý thuyết

5.1. Entropy của một tập dữ liệu chứa hai lớp với tỉ lệ 70% và 30% là:
A. 0
B. 1
C. Xấp xỉ 0.88 bit
D. Xấp xỉ 0.5 bit

5.2. Phát biểu nào sau đây SAI về Information Gain?
A. Gain càng lớn, thuộc tính càng có ích trong việc phân lớp.
B. Gain được tính bằng entropy sau khi chia trừ entropy trước khi chia.
C. ID3 chọn thuộc tính có Gain nhỏ nhất để làm nút phân nhánh.
D. Gain có thể bằng 0 nếu phân nhánh không làm giảm entropy.

5.3. Trong CART, chỉ số Gini bằng 0 khi:
A. Tất cả các mẫu thuộc cùng một lớp.
B. Các lớp phân bố đều nhau.
C. Số lượng mẫu bằng số lượng lớp.
D. Tập dữ liệu rỗng.
5.4. Tại sao cây quyết định thường cần cắt tỉa?
A. Để tăng tốc độ huấn luyện.
B. Để giảm độ sâu, tránh quá khớp và cải thiện tổng quát hóa.
C. Để tăng số lượng nút lá.
D. Để giảm số lượng thuộc tính được sử dụng.

5.5. Trong cây hồi quy, dự đoán tại nút lá là:
A. Mode của các giá trị mục tiêu.
B. Trung vị.
C. Trung bình cộng của các giá trị mục tiêu.
D. Giá trị lớn nhất.

5.6. Điểm yếu nào là cố hữu của mô hình cây quyết định?
A. Không thể phân lớp dữ liệu phi tuyến.
B. Không thể xử lý dữ liệu thiếu.
C. Kém khả năng ngoại suy ngoài phạm vi dữ liệu huấn luyện.
D. Không thể dùng cho bài toán hồi quy.

5.7. Phát biểu nào sau đây là ĐÚNG về thuật toán ID3?
A. ID3 luôn tạo ra cây nhị phân.
B. ID3 sử dụng chỉ số Gini để chọn thuộc tính phân nhánh.
C. ID3 có thể trực tiếp xử lý thuộc tính số liên tục mà không cần rời rạc hóa.
D. ID3 chọn thuộc tính có Information Gain lớn nhất để làm nút phân nhánh.

5.8. Một nhược điểm của ID3 là gì?
A. Không thể tạo ra cây đa phân nhánh.
B. Dễ bị ảnh hưởng bởi các thuộc tính có nhiều giá trị.
C. Yêu cầu dữ liệu đầu vào phải được chuẩn hóa.
D. Chỉ áp dụng được cho bài toán hồi quy.

5.9. Phát biểu nào sau đây là SAI về CART?
A. CART chỉ xây dựng cây nhị phân.
B. CART dùng chỉ số Gini cho bài toán phân lớp.
C. CART không thể áp dụng cho bài toán hồi quy.
D. CART tìm ngưỡng tối ưu cho thuộc tính số bằng cách sắp xếp và duyệt các điểm chia.

5.10. Khi xây dựng cây hồi quy, CART chọn phép phân nhánh dựa trên tiêu chí nào?
A. Information Gain
B. Chỉ số Gini
C. Reduction in Variance (Giảm phương sai)
D. Entropy của biến mục tiêu

5.11. Entropy của một tập dữ liệu chứa đúng một lớp duy nhất có giá trị là bao nhiêu?
A. 1 bit
B. 0
C. 0.5 bit
D. Không xác định

5.12. Trong thuật toán ID3, việc chọn thuộc tính phân nhánh dừng lại khi nào?
A. Khi tất cả các mẫu trong nút thuộc cùng một lớp, hoặc không còn thuộc tính nào để phân chia.
B. Khi cây đạt đến độ sâu 3.
C. Khi Information Gain của tất cả các thuộc tính đều lớn hơn 0.
D. Khi tập dữ liệu có ít hơn 100 mẫu.

5.13. Công thức Information Gain $Gain(S,A) = H(S) - \sum \frac{|S_v|}{|S|} H(S_v)$ thể hiện điều gì?
A. Tổng entropy của các tập con sau khi chia.
B. Mức giảm entropy trung bình sau khi phân nhánh theo thuộc tính A.
C. Entropy của thuộc tính A.
D. Tỉ lệ mẫu được phân lớp đúng.

5.14. Cho tập dữ liệu có 10 mẫu, lớp "Có" (6 mẫu), lớp "Không" (4 mẫu). Entropy của tập này gần nhất với giá trị nào?
A. 1.0 bit
B. 0.97 bit
C. 0.88 bit
D. 0.5 bit

5.15. Đặc điểm nào khiến ID3 không phù hợp với dữ liệu thực tế nếu không được cải tiến?
A. Chỉ xây dựng cây nhị phân.
B. Không xử lý được thuộc tính số liên tục một cách trực tiếp.
C. Luôn tạo ra cây có độ sâu lớn.
D. Yêu cầu dữ liệu phải được chuẩn hóa về [0,1].

5.16. Chỉ số Gini cho tập dữ liệu có 4 mẫu: 3 mẫu lớp A, 1 mẫu lớp B là bao nhiêu?
A. 0.375
B. 0.5
C. 0.25
D. 0.0

5.17. Trong CART phân lớp, một phép chia được coi là tốt hơn nếu:
A. Tổng Gini có trọng số của hai tập con lớn hơn Gini của nút cha.
B. Tổng Gini có trọng số của hai tập con nhỏ hơn Gini của nút cha.
C. Số lượng mẫu trong hai tập con bằng nhau.
D. Cả hai tập con đều có Gini bằng 0.5.

5.18. Khi xử lý thuộc tính hạng mục có 3 giá trị {X, Y, Z}, CART sẽ thực hiện:
A. Luôn tạo ba nhánh tương ứng với X, Y, Z.
B. Chỉ chọn một giá trị và so sánh bằng.
C. Duyệt các cách gộp thành hai nhóm (ví dụ {X} vs {Y,Z}) để tìm phép chia nhị phân tốt nhất.
D. Bỏ qua thuộc tính này vì không phải số.

5.19. Trong cây hồi quy, giá trị dự đoán tại nút lá được tính như thế nào?
A. Là giá trị xuất hiện nhiều nhất.
B. Là trung vị của các giá trị mục tiêu trong nút.
C. Là trung bình cộng của các giá trị mục tiêu trong nút.
D. Là giá trị lớn nhất của biến mục tiêu.

5.20. Reduction in Variance lớn nhất đạt được khi:

A. Phương sai của cả hai tập con đều lớn.

B. Phương sai của cả hai tập con đều nhỏ.

C. Tổng phương sai trọng số của hai tập con lớn hơn phương sai nút cha.

D. Phương sai của một tập con bằng 0, tập còn lại bằng phương sai nút cha.

B. Câu hỏi tự luận và bài tập

5.21: Tính toán ID3 bằng tay

Cho tập dữ liệu về việc có nên đi du lịch hay không:

Thời tiết	**Gió**	**Đi du lịch**
Nắng	Mạnh	Không
Nắng	Nhẹ	Có
Mưa	Mạnh	Không
Mưa	Nhẹ	Có
Âm u	Mạnh	Có

a) Tính Entropy của toàn bộ tập dữ liệu.
b) Tính Information Gain cho từng thuộc tính.
c) Vẽ cây quyết định do ID3 tạo ra (có thể thực hiện thêm bước nếu cần).

5.22: Cài đặt thuật toán ID3 bằng Python
Sử dụng tập dữ liệu "Mua máy tính" trong bảng dưới đây.
Bảng dữ liệu Mua máy tính

ID	Tuổi	Thu nhập	Sinh viên	Đánh giá tín dụng	Mua máy tính
1	Trẻ	Cao	Không	Tốt	Không
2	Trẻ	Cao	Không	Xuất sắc	Không
3	Trung niên	Cao	Không	Tốt	Có
4	Già	Trung bình	Không	Tốt	Có
5	Già	Thấp	Có	Tốt	Có
6	Già	Thấp	Có	Xuất sắc	Không
7	Trung niên	Thấp	Có	Xuất sắc	Có
8	Trẻ	Trung bình	Không	Tốt	Không
9	Trẻ	Thấp	Có	Tốt	Có
10	Già	Trung bình	Có	Tốt	Có
11	Trẻ	Trung bình	Có	Xuất sắc	Có
12	Trung niên	Trung bình	Không	Xuất sắc	Có
13	Trung niên	Cao	Có	Tốt	Có
14	Già	Trung bình	Không	Xuất sắc	Không

Yêu cầu:
- Xây dựng hàm 'build_tree' sử dụng ID3 để trả về cây dưới dạng dictionary.
- Viết hàm 'predict' cho phép dự đoán nhãn của một mẫu mới dựa trên cây đã xây.
- Kiểm tra trên một vài mẫu thử.

5.23: Thực hành CART với scikit-learn
Dùng tập dữ liệu Iris (có sẵn trong 'sklearn.datasets'):
- Huấn luyện một 'DecisionTreeClassifier' với tiêu chí Gini, không giới hạn độ sâu.
- Vẽ cây và nhận xét các nút.
- Thay đổi 'max_depth' thành 2 và 3, so sánh độ chính xác trên tập train/test (dùng 'train_test_split'). Nhận xét về hiện tượng quá khớp.

5.24: CART Hồi quy
Tạo tập dữ liệu giả lập 50 điểm với quan hệ $y = 2 * x + \sin(x) +$ nhiễu (dùng 'numpy').
- Huấn luyện 'DecisionTreeRegressor' với 'max_depth' lần lượt là 2, 5, 10.
- Vẽ biểu đồ dự đoán của từng mô hình trên cùng một đồ thị với dữ liệu gốc.
- Giải thích tại sao mô hình sâu nhất lại có thể không tốt nhất trên dữ liệu mới.

5.25: Viết chương trình Python thực hiện:
- Đọc dữ liệu từ file CSV chứa thông tin khách hàng (tự tạo).
- Xây dựng cây phân lớp và cây hồi quy (nếu có biến mục tiêu số).
- Thực hiện cắt tỉa bằng cách thay đổi 'min_samples_leaf'.
- In ra tầm quan trọng của các đặc trưng.
- Trực quan hóa cây và lưu thành file ảnh.

Chương 6 HỒI QUY LOGISTIC, MÁY VECTOR HỖ TRỢ

A. Câu hỏi trắc nghiệm lý thuyết

Chọn đáp án đúng nhất.

6.1. Hàm sigmoid $\sigma(z) = 1/(1 + e^{-z})$ có giá trị đầu ra thuộc khoảng nào?
A. $[0, \infty)$ B. $(-1,1)$ C. $(0,1)$ D. $[0,1]$

6.2. Trong logistic regression, hàm mất mát thường dùng là:
A. Mean Squared Error (MSE)
B. Binary Cross-Entropy
C. Hinge loss
D. Mean Absolute Error

6.3. Điều nào sau đây đúng về hàm mất mát cross-entropy trong logistic regression?
A. Luôn có nghiệm dạng đóng
B. Là hàm lồi theo tham số mô hình
C. Không phân biệt được với MSE
D. Chỉ dùng cho bài toán đa lớp

6.4. Đạo hàm của J theo w_j trong logistic regression có dạng $\frac{1}{N}\sum_i(\hat{y}_i - y_i)x_{ij}$. Vậy tại điểm dữ liệu được dự đoán đúng với xác suất rất cao ($\hat{y}_i \approx 1$ và $y_i = 1$), gradient đóng góp:
A. Lớn âm B. Lớn dương C. Gần bằng 0 D. Bằng 1

6.5. Mục tiêu của nguyên lý hợp lý cực đại (MLE) trong logistic regression là gì?
A. Cực tiểu khoảng cách hình học
B. Cực đại xác suất quan sát được dữ liệu huấn luyện
C. Cực đại margin
D. Cực tiểu số lượng tham số

6.6. Trong SVM tuyến tính, margin được tính bằng:
A. $\| w \|$
B. $1/\| w \|$
C. $2/\| w \|$
D. $\| w \|^2$

6.7. Support vectors là những điểm:
A. Nằm sai phía siêu phẳng
B. Nằm đúng siêu phẳng
C. Có $\alpha_i > 0$ trong bài toán đối ngẫu
D. Có khoảng cách đến siêu phẳng nhỏ hơn 1

6.8. Trong SVM lề mềm, tham số C lớn dẫn đến:
A. Margin rộng hơn, chấp nhận nhiều điểm vi phạm
B. Margin hẹp hơn, hạn chế điểm vi phạm
C. Tăng số lượng support vectors
D. Bỏ qua hoàn toàn dữ liệu nhiễu

6.9. Bài toán đối ngẫu của SVM có bao nhiêu biến?
A. Bằng số chiều của dữ liệu
B. Bằng số mẫu huấn luyện N
C. Luôn bằng 2
D. Bằng số support vectors

6.10. Khi sử dụng kernel trick trong SVM, dữ liệu được ánh xạ tường minh lên không gian đặc trưng.
A. Đúng B. Sai

6.11. Mô hình logistic regression dùng hàm sigmoid để làm gì?
A. Biến đổi đầu ra thành một số thực bất kỳ.
B. Biến đổi tổ hợp tuyến tính z thành một giá trị trong khoảng (0,1) để biểu diễn xác suất.
C. Tạo ra một đường thẳng phân cách hai lớp.
D. Tính khoảng cách từ điểm dữ liệu đến đường biên.

6.12. Hàm mất mát Binary Cross-Entropy cho một mẫu $(\boldsymbol{x}_i, y_i)$ với dự đoán $\hat{y}_i$ là:
A. $-[y_i \log \hat{y}_i + (1 - y_i)\log(1 - \hat{y}_i)]$
B. $(y_i - \hat{y}_i)^2$
C. $| y_i - \hat{y}_i |$
D. $\max(0, 1 - y_i \hat{y}_i)$

6.13. Khi nào gradient của logistic regression đối với một mẫu gần bằng 0?
A. Khi mẫu đó bị phân lớp sai hoàn toàn.
B. Khi mẫu đó ở rất xa đường biên.
C. Khi dự đoán $\hat{y}_i$ rất gần với nhãn thật y_i (mô hình tự tin và đúng).
D. Khi learning rate bằng 0.

6.14. Trong logistic regression, đạo hàm $\frac{\partial J}{\partial w_j} = \frac{1}{N}\sum(\hat{y}_i - y_i)x_{ij}$. Điều gì xảy ra nếu tất cả x_{ij} đều bằng 0?

A. Gradient bằng 0, trọng số w_j không thay đổi.

B. Gradient bằng vô cùng.

C. Mô hình tự động thêm bias.

D. Hàm sigmoid trả về 0.

6.15. Vì sao hàm mất mát Mean Squared Error ít được dùng cho logistic regression?

A. Vì MSE luôn dương.

B. Vì MSE làm cho bài toán không lồi, dễ kẹt cực tiểu địa phương.

C. Vì MSE không khả vi.

D. Vì MSE chỉ dùng cho hồi quy tuyến tính.

6.16. Trong SVM tuyến tính (lề cứng), chúng ta cực tiểu $\frac{1}{2}\|w\|^2$ nhằm mục đích gì?

A. Giảm số lượng support vectors.

B. Tăng bias của mô hình.

C. Cực đại margin giữa hai lớp.

D. Đảm bảo mọi điểm đều được phân đúng.

6.17. Trong bài toán đối ngẫu của SVM, những mẫu nào có $\alpha_i = 0$?

A. Các support vectors.

B. Các điểm nằm trong margin.

C. Các điểm bị phân lớp sai.

D. Các điểm nằm ngoài margin, được phân lớp đúng và không ảnh hưởng đến siêu phẳng.

6.18. Vai trò của tham số C trong SVM lề mềm là gì?

A. Quyết định số chiều của không gian đặc trưng.

B. Đánh đổi giữa độ rộng margin và mức phạt đối với các điểm vi phạm margin.

C. Xác định tốc độ học của thuật toán tối ưu.

D. Là ngưỡng để quyết định lớp của một điểm.

6.19. Một điểm dữ liệu bị phân lớp sai trong SVM lề mềm sẽ có:

A. $\xi_i = 0$

B. $0 < \xi_i < 1$

C. $\xi_i > 1$

D. $\xi_i < 0$

6.20. Kernel trick trong SVM cho phép:

A. Giảm số lượng mẫu huấn luyện.

B. Tính toán trực tiếp trong không gian đầu vào mà không cần ánh xạ đặc trưng.

C. Ngầm ánh xạ dữ liệu lên không gian đặc trưng nhiều chiều hơn mà không cần tính tường minh ánh xạ.
D. Loại bỏ các điểm nhiễu.

B. Câu hỏi tự luận và bài tập

Bài 1 (Tính toán logistic regression).
Cho tập dữ liệu 3 điểm: $(x = 1, y = 0)$, $(2, y = 0)$, $(4, y = 1)$. Giả sử mô hình logistic với $w = 0.5, b = -1.5$.
a) Tính xác suất dự đoán $\hat{y}$ cho từng điểm.
b) Tính giá trị hàm mất mát cross-entropy trung bình trên 3 điểm.
c) Tính gradient của w và b trên toàn bộ tập dữ liệu.
d) Nếu learning rate $\eta = 0.5$, hãy cập nhật w, b sau một epoch.

Bài 2 (Cài đặt logistic regression).
Sử dụng Python, cài đặt thuật toán gradient descent cho logistic regression (không dùng sklearn) với hai thuộc tính đầu của tập Iris (hai lớp setosa và versicolor). Vẽ đồ thị loss theo epoch và biểu diễn đường biên phân lớp trên mặt phẳng hai chiều. Thử nghiệm ít nhất 3 learning rate khác nhau và nhận xét.

Bài 3 (Tính toán SVM).
Cho tập dữ liệu 2D: lớp +1: (0,0), (1,0); lớp -1: (2,1), (3,1). Bằng trực giác hình học, hãy xác định siêu phẳng phân cách tối ưu (hard-margin). Tính $\mathbf{w}, b$, chỉ ra support vectors và margin tương ứng. (Không cần giải bài toán đối ngẫu.)

Bài 4 (Thực hành SVM).
Dùng tập Breast Cancer từ sklearn.datasets.
a) Huấn luyện SVM tuyến tính với $C = 0.1, C = 1, C = 10$. So sánh số support vectors và độ chính xác trên tập test. Giải thích ảnh hưởng của C.
b) Thử SVM với kernel RBF, thay đổi tham số γ và C. Vẽ đồ thị đường biên trên hai chiều đầu tiên (dùng PCA nếu cần) và nhận xét về hiện tượng overfitting.

Bài 5 (Tính toán SVM).
Cho tập dữ liệu 2D gồm ba điểm:

- $A(1,1)$ thuộc lớp +1,
- $B(2,2)$ thuộc lớp +1,
- $C(2,0)$ thuộc lớp -1.

Giả sử đây là bài toán phân tách tuyến tính hoàn hảo (có thể kiểm tra).
a) Hãy chỉ ra support vectors và tìm siêu phẳng phân cách tối ưu theo hard-margin SVM (tức xác định $\mathbf{w}$ và b).
b) Tính margin tương ứng.
c) Kiểm tra xem điểm $B(2,2)$ có phải là support vector không. Giải thích.

Chương 7 HỌC KHÔNG GIÁM SÁT

A. Câu hỏi trắc nghiệm lý thuyết 30 câu

Hãy chọn đáp án đúng nhất cho mỗi câu.

K-means

7.1 K-means thuộc loại học nào?
A. Học có giám sát
B. Học không giám sát
C. Học bán giám sát
D. Học tăng cường

7.2 Trong K-means, mỗi cụm được đại diện bởi:
A. Điểm xa nhất trong cụm
B. Trung vị của các điểm trong cụm
C. Trung bình của các điểm trong cụm
D. Điểm gần tâm nhất

7.3 Hàm mục tiêu mà K-means cố gắng tối thiểu là:
A. Tổng bình phương khoảng cách giữa các cụm
B. Tổng bình phương khoảng cách nội cụm (WCSS)
C. Chỉ số silhouette
D. Log-likelihood

7.4 Phát biểu nào về sự hội tụ của K-means là đúng?
A. Luôn hội tụ đến cực tiểu toàn cục của hàm mất mát
B. Có thể dao động không hội tụ
C. Hội tụ đến cực tiểu cục bộ sau số hữu hạn bước
D. Không bao giờ hội tụ nếu dữ liệu nhiễu

7.5 Trong thuật toán K-means cơ bản, tâm cụm được cập nhật như thế nào?
A. Bằng điểm dữ liệu gần nhất với tâm cũ
B. Bằng trung vị các điểm trong cụm
C. Bằng trung bình các điểm trong cụm
D. Bằng cách gradient descent

7.6 Khởi tạo tâm trong K-means có ảnh hưởng gì?
A. Không ảnh hưởng gì vì luôn hội tụ cùng kết quả
B. Ảnh hưởng đến tốc độ hội tụ và chất lượng phân cụm cuối cùng
C. Chỉ ảnh hưởng đến số vòng lặp, không ảnh hưởng đến kết quả
D. Ảnh hưởng nhưng có thể bỏ qua nếu dùng Euclidean

7.7 K-means++ khác gì so với khởi tạo ngẫu nhiên thông thường?
A. Chọn các tâm ban đầu hoàn toàn ngẫu nhiên
B. Chọn tâm đầu tiên là gốc tọa độ
C. Chọn các tâm sao cho chúng ở xa nhau với xác suất cao
D. Chọn tâm là các điểm gần biên nhất

7.8 Độ phức tạp của một vòng lặp K-means với N điểm, K cụm, d chiều là:
A. $O(N \cdot d)$
B. $O(N \cdot K \cdot d)$
C. $O(K^2 \cdot d)$
D. $O(N \cdot \log N)$

7.9 Khi số cụm K tăng, WCSS (inertia) thường:
A. Luôn tăng
B. Luôn giảm
C. Giữ nguyên
D. Tăng rồi giảm

7.10 Nhược điểm cơ bản của K-means là gì?
A. Không thể xử lý dữ liệu nhiều chiều
B. Cần biết trước số cụm K và giả định cụm hình cầu
C. Luôn cho kết quả khác nhau
D. Chỉ chạy được trên dữ liệu số ít hơn 1000 điểm
7.11 Trong bước gán nhãn, một điểm được gán vào cụm có:
A. Tâm xa nhất
B. Tâm gần nhất theo khoảng cách Euclid
C. Mật độ cao nhất
D. Chỉ số silhouette cao nhất

7.12 K-means có thể áp dụng với độ đo khoảng cách nào?
A. Chỉ Euclidean
B. Euclidean và Manhattan
C. Bất kỳ metric nào
D. Chỉ Cosine similarity

7.13 Để chọn K, phương pháp "elbow" dựa trên:
A. Đồ thị WCSS theo K, tìm điểm khuỷu tay
B. Độ chính xác phân lớp
C. Giá trị log-likelihood
D. Số tâm hội tụ

7.14 Khi hai cụm thực sự có hình dạng không lồi (ví dụ vòng tròn đồng tâm), K-means sẽ:
A. Phân tách hoàn hảo
B. Gặp khó khăn và thường phân sai
C. Chỉ cần tăng K là được
D. Không hoạt động

7.15 Thuật ngữ "inertia" trong scikit-learn tương ứng với:
A. Tổng khoảng cách từ điểm đến tâm
B. Tổng bình phương khoảng cách đến tâm (WCSS)
C. Số vòng lặp cần để hội tụ
D. Số điểm bị gán sai

7.16 Điều gì xảy ra nếu trong quá trình chạy, một cụm trở thành rỗng?
A. Thuật toán dừng ngay
B. Tâm cụm đó được giữ nguyên
C. Tâm cụm đó có thể được khởi tạo lại hoặc bị loại bỏ
D. Tất cả các điểm được gán lại vào cụm đó

7.17 So với k-medoids (PAM), K-means khác ở:
A. Dùng điểm thực làm đại diện (medoid)
B. Dùng trung bình (mean) có thể không trùng điểm dữ liệu nào
C. Sử dụng khoảng cách Mahalanobis
D. Không cần chỉ định K

7.18 Sau khi K-means hội tụ, nếu ta tiếp tục chạy thêm vòng lặp thì:
A. Các tâm tiếp tục thay đổi
B. Gán nhãn có thể khác nếu tâm thay đổi
C. Các tâm và nhãn không thay đổi (dừng)
D. J tiếp tục giảm

7.19 Ý tưởng chính của K-means có thể xem như trường hợp đặc biệt của thuật toán nào?
A. Gradient boosting
B. Kỳ vọng - cực đại hóa (EM) cho Gaussian mixture với hiệp phương sai cầu
C. Support vector machine
D. Hồi quy logistic

7.20 Khi tập dữ liệu có các đặc trưng với thang đo rất khác biệt (tuổi từ 0-100, thu nhập từ 0-100 triệu), bạn nên làm gì trước khi áp dụng K-means?
A. Không cần làm gì
B. Chuẩn hóa dữ liệu (standardize / normalize)
C. Tăng K lên gấp đôi
D. Đổi sang độ đo cosine

DBSCAN

7.21 DBSCAN là viết tắt của:

A. Density-Based Spatial Clustering of Applications with Noise

B. Distribution-Based Sampling Clustering and Noise

C. Distance-Based Scanning Clustering Algorithm

D. Data-Based Smart Clustering Network

7.22 Tham số nào không có trong DBSCAN?

A. ε (eps)

B. $minPts$

C. Số cụm K

D. Hàm khoảng cách

7.23 Một điểm được gọi là core point nếu:

A. Nó nằm ở trung tâm cụm

B. Nó có ít nhất $minPts$ điểm trong ε-lân cận

C. Nó có khoảng cách đến mọi điểm khác $\leq \varepsilon$

D. Nó không có láng giềng nào

7.24 Điểm border point:

A. Là core point nhưng ở rìa cụm

B. Không phải core, nhưng nằm trong lân cận của một core point

C. Luôn là nhiễu

D. Là điểm có đúng $minPts$ hàng xóm

7.25 Trong DBSCAN, một cụm được định nghĩa là:

A. Tập các điểm gần tâm cụm nhất

B. Tập tối đại các điểm density-connected

C. Tập các điểm có khoảng cách đến một tâm nhỏ hơn ε

D. Tập các điểm được gán cùng nhãn bởi K-means

7.26 Điểm nhiễu (noise) là:

A. Điểm không thuộc bất kỳ cụm nào

B. Điểm nằm trong cụm nhưng xa tâm

C. Điểm core nhưng không có border

D. Điểm có mật độ cao nhất

7.27 DBSCAN có ưu điểm gì so với K-means?

A. Luôn nhanh hơn

B. Không cần chỉ định số cụm, phát hiện được nhiễu và cụm hình dạng bất kỳ

C. Không cần tham số nào

D. Hoạt động tốt với dữ liệu nhiều chiều mà không cần tiền xử lý

7.28 Hạn chế chính của DBSCAN là gì?

A. Không thể chạy trên dữ liệu hơn 1000 điểm

B. Rất nhạy cảm với tham số ε và $minPts$, khó khăn khi mật độ cụm khác nhau lớn

C. Chỉ phát hiện được các cụm hình cầu

D. Luôn yêu cầu dữ liệu được chuẩn hóa

7.29 Khi ε được đặt quá lớn, DBSCAN có xu hướng:

A. Tạo ra nhiều cụm nhỏ

B. Hợp nhất tất cả điểm thành một cụm hoặc rất ít cụm

C. Đánh dấu mọi điểm là nhiễu

D. Không có tác động gì

7.30 Khi $minPts$ tăng, số điểm được coi là core:

A. Tăng lên

B. Giảm đi

C. Không thay đổi

D. Không phụ thuộc

B. Câu hỏi tự luận và bài tập

K-means

Bài 1 (Tính tay):

Cho tập điểm: A(2,5), B(3,2), C(5,1), D(6,4), E(7,3), F(4,4). Sử dụng K-means với K=2, khởi tạo tâm $\mu_1 = A(2,5), \mu_2 = E(7,3)$. Thực hiện hai vòng lặp đầy đủ. Xác định nhãn và tâm sau mỗi bước. Tính WCSS cuối cùng.

Bài 2 (Cài đặt thủ công):

Viết class MyKMeans bằng Python với các phương thức fit(X, K, max_iters=100). Không dùng thư viện sklearn cho phần thuật toán. Áp dụng với tập dữ liệu Iris (chỉ lấy 2 cột đầu tiên: sepal length, sepal width) sau khi bỏ nhãn loài. So sánh kết quả phân cụm với nhãn thật bằng cách vẽ biểu đồ phân tán và tính chỉ số Rand index.

Bài 3 (Elbow method):

Sử dụng K-means của sklearn trên tập dữ liệu make_blobs với 500 mẫu, 5 tâm thực. Với K từ 1 đến 10, tính inertia và vẽ đường cong "elbow". Quan sát và chọn K hợp lý. So sánh với ground truth.

Bài 4 (Nén ảnh):

Dùng K-means để giảm số màu trong một ảnh (ví dụ ảnh hoa hoặc chân dung). Coi mỗi pixel là một điểm dữ liệu trong không gian RGB. Sau khi phân cụm (chọn K=16), thay thế mỗi pixel bằng tâm cụm tương ứng. Hiển thị ảnh gốc và ảnh sau nén. Tính tỉ lệ nén (về mặt số màu).

Bài 5 (So sánh khởi tạo):
Tạo tập dữ liệu 2D gồm 3 cụm dài, hẹp và lệch nhau (dùng make_classification hoặc tự tạo). Thực hiện K-means với hai cách khởi tạo: random và k-means++. Với mỗi cách, chạy 20 lần độc lập, ghi lại inertia cuối cùng. Vẽ histogram của inertia cho hai cách, nhận xét.

Bài 6 (Tính tay):
Cho tập điểm 1D: {1, 2, 3, 10, 11, 12, 50}. Dùng DBSCAN với $\varepsilon = 2, minPts = 2$. Xác định core point, border point, noise, và các cụm. (Gợi ý: khoảng cách trong 1D là trị tuyệt đối.)

Bài 7 (Cài đặt thủ công):
Viết class MyDBSCAN bằng Python, thực hiện thuật toán DBSCAN từ đầu (không dùng sklearn.cluster). Thuật toán nên xây dựng ma trận khoảng cách và xác định core, mở rộng vùng. So sánh kết quả với sklearn.cluster.DBSCAN trên tập dữ liệu make_blobs có thêm nhiễu.

Bài 8 (Khám phá tham số):
Sử dụng tập dữ liệu make_circles (tạo hai vòng tròn đồng tâm, noise=0.05). Thử DBSCAN với các cặp $(\varepsilon, minPts)$: (0.2,5), (0.5,5), (1.0,5) và (0.5,10). Trực quan hóa và nhận xét kết quả. Từ đó, chỉ ra vai trò của mỗi tham số.

Chương 8 HỌC KẾT HỢP - ENSEMBLE LEARNING

A. Câu hỏi trắc nghiệm lý thuyết

Hãy chọn đáp án đúng nhất.

8.1 Ý tưởng chính của học kết hợp là gì?
A. Dùng một mô hình phức tạp duy nhất.
B. Kết hợp nhiều mô hình con để đạt hiệu quả cao hơn.
C. Tăng số đặc trưng để cải thiện dự đoán.
D. Giảm số mẫu huấn luyện để tránh overfitting.

8.2 Bootstrapping là kỹ thuật:
A. Lấy mẫu ngẫu nhiên không hoàn lại.
B. Lấy mẫu ngẫu nhiên có hoàn lại cùng kích thước với mẫu gốc.
C. Tăng cường dữ liệu bằng nhiễu.
D. Chuẩn hóa dữ liệu.

8.3 Xác suất một quan sát không xuất hiện trong một mẫu bootstrap (kích thước n) xấp xỉ:
A. 0.5
B. 0.632
C. 0.368
D. 0.1

8.4 Trong bagging, các mô hình con được huấn luyện:
A. Tuần tự, mỗi mô hình dựa vào lỗi mô hình trước.
B. Độc lập trên cùng một tập dữ liệu.
C. Độc lập trên các mẫu bootstrap khác nhau.
D. Đồng thời chia sẻ trọng số.

8.5 Bagging giúp giảm loại sai số nào hiệu quả nhất?
A. Độ lệch (bias)
B. Phương sai (variance)
C. Nhiễu không thể giảm
D. Cả bias và variance như nhau

8.6 Trong Random Forest, mục đích của việc chọn ngẫu nhiên tập con đặc trưng tại mỗi nút là gì?
A. Tăng độ chính xác của từng cây.
B. Giảm tương quan giữa các cây.
C. Giảm số lượng cây cần dùng.
D. Giúp mỗi cây nhanh hơn.
8.7 Giá trị mặc định của số đặc trưng xét tại mỗi nút cho bài toán phân loại trong Random Forest thường là:
A. p
B. $\sqrt{p}$
C. $\log_2 p$
D. $p/3$

8.8 Out-of-bag (OOB) là gì?
A. Lỗi trên tập huấn luyện.
B. Tập dữ liệu không được dùng trong bootstrap.
C. Phương pháp đánh giá mô hình dùng chính các mẫu không có trong mẫu bootstrap cho mỗi quan sát.
D. Kỹ thuật chọn đặc trưng.

8.9 Trong bagging, dự đoán cuối cùng cho hồi quy là:
A. Trung vị các dự đoán thành phần.
B. Trung bình các dự đoán thành phần.
C. Biểu quyết đa số.
D. Dự đoán của cây đầu tiên.

8.10 Trong boosting, các mô hình con được huấn luyện:
A. Độc lập.
B. Song song.
C. Tuần tự, mô hình sau tập trung sửa lỗi của mô hình trước.
D. Trên cùng một mẫu bootstrap.

8.11 AdaBoost cập nhật điều gì sau mỗi vòng lặp?
A. Nhãn của dữ liệu.
B. Trọng số của các mẫu huấn luyện.
C. Số đặc trưng.
D. Hàm mất mát.

8.12 Công thức tính trọng số của weak learner thứ t trong AdaBoost: $\alpha_t = \frac{1}{2}\ln\left(\frac{1-\epsilon_t}{\epsilon_t}\right)$.
Khi $\epsilon_t = 0.1$ thì α_t xấp xỉ:
A. 0.0
B. 1.1
C. 2.2
D. 0.5
8.13 Điều kiện để AdaBoost tiếp tục thêm weak learner?
A. $\epsilon_t > 0.5$
B. $\epsilon_t < 0.5$ (tốt hơn đoán ngẫu nhiên).
C. $\epsilon_t = 1$
D. Không phụ thuộc ϵ_t.

8.14 Gradient Boosting khác AdaBoost cơ bản ở điểm nào?
A. Dùng bagging thay vì boosting.
B. Tối ưu hóa trực tiếp hàm mất mát bằng cách khớp phần dư.
C. Chỉ dùng cho hồi quy.
D. Không điều chỉnh trọng số.

8.15 Trong Gradient Boosting với squared loss, mỗi cây mới khớp với:
A. Nhãn gốc y.
B. Trọng số mẫu.
C. Phần dư $y - F_{m-1}(x)$.
D. Đặc trưng ngẫu nhiên.

8.16 Tại sao Random Forest thường ít overfitting hơn một cây quyết định đơn lẻ?
A. Vì số cây ít hơn.
B. Vì tính trung bình của nhiều cây và ngẫu nhiên hóa giảm phương sai.
C. Vì dùng toàn bộ đặc trưng.
D. Vì cắt tỉa tất cả các cây.

8.17 XGBoost là một cải tiến của:
A. Random Forest
B. Bagging
C. Gradient Boosting
D. AdaBoost

8.18 Lỗi OOB trong Random Forest có thể thay thế cho:
A. Tập huấn luyện
B. Tập kiểm tra (validation/test) để ước lượng sai số tổng quát.
C. Tập dữ liệu thô
D. Ma trận nhầm lẫn

8.19 Khi tăng số lượng cây trong Random Forest (số cây lớn), điều gì thường xảy ra?
A. Mô hình nhanh chóng overfit.
B. Lỗi OOB tăng lên.
C. Lỗi tổng quát giảm dần rồi bão hòa, không tăng.
D. Phương sai của ensemble tăng mạnh.
8.20 Trong bagging, nếu base learner có độ lệch thấp và phương sai cao, bagging có tác dụng gì?
A. Giảm độ lệch.
B. Tăng độ lệch, giảm phương sai.
C. Giảm phương sai, giữ nguyên độ lệch.
D. Tăng cả phương sai và độ lệch.

B. Câu hỏi tự luận và bài tập

Bài 1 - Bootstrap cho trung bình

Cho mẫu điểm: [58, 70, 82, 95, 63, 77, 88, 69, 73, 85]. Hãy tự viết code Python (không dùng sklearn) để tạo 2000 mẫu bootstrap, tính trung bình mỗi mẫu và xác định khoảng tin cậy 95% cho trung bình tổng thể bằng phương pháp percentile. Vẽ histogram của phân phối bootstrap.

Bài 2 - Bagging bằng tay với cây nhỏ

Cho tập dữ liệu gồm 6 mẫu với 1 đặc trưng x và nhãn $y \in \{0,1\}$:

X	1.0	2.0	3.0	4.0	5.0	6.0
Y	0	0	0	1	1	1

Giả sử ta tạo 3 mẫu bootstrap (có thể bằng tay):

- Mẫu 1: {x=1,1,4,5,5,6} với nhãn tương ứng.
- Mẫu 2: {x=2,3,3,4,6,6}
- Mẫu 3: {x=1,2,4,4,5,6}

Trên mỗi mẫu, xây dựng một cây quyết định một nút (decision stump) tốt nhất (dùng tiêu chí Gini) với ngưỡng chia tại 3.5. Sau đó, xác định dự đoán cuối cùng cho mẫu $x = 4.0$ bằng biểu quyết đa số của 3 cây. (Yêu cầu tính tay, trình bày rõ các bước).

Bài 3 - Random Forest OOB

Sử dụng tập dữ liệu load_digits của sklearn. Huấn luyện Random Forest 500 cây với oob_score=True. Trình bày code và cho biết OOB score là bao nhiêu. So sánh với kết quả cross-validation 5-fold để thấy sự tương đồng. Giải thích vì sao OOB có thể thay thế tập validation.

Bài 4 - AdaBoost tự cài đặt với Decision Stump

Cho tập dữ liệu 1D: X = [1,2,3,4,5,6,7,8], y = [-1,-1,-1,1,1,1,1,1]. Hãy cài đặt thuật toán AdaBoost từ đầu (chỉ sử dụng numpy, không dùng sklearn) với T=3 vòng. Ở mỗi vòng, tìm decision stump tốt nhất (ngưỡng và hướng) bằng cách duyệt, cập nhật trọng số và in ra trọng số alpha. Cuối cùng in ra dự đoán của ensemble trên toàn tập. (Tham khảo code mẫu đã hướng dẫn, nhưng sinh viên phải tự viết lại và giải thích).

Bài 5 - So sánh các phương pháp ensemble

Sử dụng tập dữ liệu make_classification (sklearn) với 1000 mẫu, 20 đặc trưng (trong đó có 5 thông tin). Chia tập train/test 80/20. Thực hành:

- Huấn luyện BaggingClassifier với DecisionTree.
- Huấn luyện RandomForestClassifier.
- Huấn luyện AdaBoostClassifier với DecisionTreeClassifier(max_depth=1).
- Huấn luyện GradientBoostingClassifier.

Tất cả đều dùng 100 bộ ước lượng. So sánh độ chính xác và thời gian huấn luyện (dùng time). Viết báo cáo ngắn nhận xét về sự khác biệt, ưu nhược điểm của mỗi phương pháp dựa trên lý thuyết đã học.

ĐÁP ÁN BÀI TẬP TRẮC NGHIỆM

Chương 1:

Câu hỏi	1.1	1.2	1.3	1.4	1.5	1.6	1.7	1.8	1.9	1.10
Câu trả lời	C	C	B	C	C	B	C	C	B	A
Câu hỏi	1.11	1.12	1.13	1.14	1.15	1.16	1.17	1.18	1.19	1.20
Câu trả lời	B	C	B	C	B	C	C	B	B	C

Chương 2:

Câu hỏi	2.1	2.2	2.3	2.4	2.5	2.6	2.7	2.8	2.9	2.10
Câu trả lời	B	B	B	C	B	A	A	C	B	B
Câu hỏi	2.11	2.12	2.13	2.14	2.15	2.16	2.17	2.18	2.19	2.20
Câu trả lời	D	D	C	C	C	B	B	B	D	C

Chương 3:

Câu hỏi	3.1	3.2	3.3	3.4	3.5	3.6	3.7	3.8	3.9	3.10
Câu trả lời	B	C	C	A	B	C	C	C	B	B
Câu hỏi	3.11	3.12	3.13	3.14	3.15	3.16	3.17	3.18	3.19	3.20
Câu trả lời	C	C	B	B	D	A	B	A	D	D

Chương 4:

Câu hỏi	4.1	4.2	4.3	4.4	4.5	4.6	4.7	4.8	4.9	4.10
Câu trả lời	B	C	B	C	C	A	B	B	D	A
Câu hỏi	4.11	4.12	4.13	4.14	4.15	4.16	4.17	4.18	4.19	4.20
Câu trả lời	D	C	B	A	B	C	A	C	C	D

Chương 5:

Đáp án gợi ý:

Câu hỏi	5.1	5.2	5.3	5.4	5.5	5.6	5.7	5.8	5.9	5.10
Câu trả lời	C	B	A	B	C	C	D	B	C	C
Câu hỏi	5.11	5.12	5.13	5.14	5.15	5.16	5.17	5.18	5.19	5.20
Câu trả lời	B	A	B	B	B	A	B	C	C	B

Chương 6:S

Câu hỏi	6.1	6.2	6.3	6.4	6.5	6.6	6.7	6.8	6.9	6.10
Câu trả lời	C	B	B	C	B	C	C	B	B	B
Câu hỏi	6.11	6.12	6.13	6.14	6.15	6.16	6.17	6.18	6.19	6.20
Câu trả lời	B	A	C	A	B	C	D	B	C	C

Chương 7:

Câu hỏi	7.1	7.2	7.3	7.4	7.5	7.6	7.7	7.8	7.9	7.10
Câu trả lời	B	C	B	C	C	B	C	B	B	B
Câu hỏi	7.11	7.12	7.13	7.14	7.15	7.16	7.17	7.18	7.19	7.20
Câu trả lời	B	A	A	B	B	C	B	C	B	B
Câu hỏi	7.21	7.22	7.23	7.24	7.25	7.26	7.27	7.28	7.29	7.30
Câu trả lời	A	C	B	B	B	A	B	B	B	B

Chương 8:

Câu hỏi	8.1	8.2	8.3	8.4	8.5	8.6	8.7	8.8	8.9	8.10
Câu trả lời	B	B	C	C	B	B	B	C	B	C
Câu hỏi	8.11	8.12	8.13	8.14	8.15	8.16	8.17	8.18	8.19	8.20
Câu trả lời	B	B	B	B	C	B	C	B	C	C